

# Notas de Aula - Semana 2

## Introdução às Redes Neurais

### *Curso de Redes Neurais*

Eduardo Adame

20 de agosto de 2025

## Sumário

<b>1</b>	<b>Introdução</b>	<b>3</b>
1.1	Objetivos de Aprendizagem . . . . .	3
1.2	Conexão com a Aula Anterior . . . . .	3
<b>2</b>	<b>Inspiração Biológica</b>	<b>3</b>
2.1	O Neurônio Biológico . . . . .	3
2.2	Do Biológico ao Artificial . . . . .	4
<b>3</b>	<b>O Neurônio Artificial</b>	<b>4</b>
3.1	Modelo Matemático . . . . .	4
3.2	Relação com Regressão Logística . . . . .	5
<b>4</b>	<b>Funções de Ativação</b>	<b>5</b>
4.1	Por que Funções de Ativação? . . . . .	5
4.2	Função Sigmoid . . . . .	6
4.3	Outras Funções de Ativação Comuns . . . . .	6
4.3.1	Tangente Hiperbólica (tanh) . . . . .	6
4.3.2	ReLU (Rectified Linear Unit) . . . . .	7
<b>5</b>	<b>Redes Neurais Feedforward</b>	<b>7</b>
5.1	Arquitetura em Camadas . . . . .	7
5.2	Notação . . . . .	7
5.3	Forward Pass . . . . .	8
5.4	Representação Matricial . . . . .	8
<b>6</b>	<b>Exemplo Prático</b>	<b>8</b>
6.1	Rede com 2 Camadas Ocultas . . . . .	8
6.2	Função Softmax . . . . .	9
<b>7</b>	<b>Por que Redes Profundas?</b>	<b>9</b>
7.1	Limitações de um Único Neurônio . . . . .	9
7.2	Poder das Redes Multicamadas . . . . .	9
7.3	Profundidade vs. Largura . . . . .	10

<b>8 Conclusão</b>	<b>10</b>
8.1 Principais Conceitos Abordados . . . . .	10

# 1 Introdução

Nesta segunda aula, fazemos a transição dos métodos tradicionais de machine learning para as redes neurais artificiais. Veremos como o conceito de regressão logística, que estudamos na semana passada, se generaliza para criar modelos muito mais poderosos e flexíveis.

As redes neurais representam um paradigma fundamental no aprendizado de máquina moderno. Inspiradas pelo funcionamento do cérebro humano, essas estruturas computacionais são capazes de aprender representações hierárquicas complexas dos dados, tornando-se a base para os avanços recentes em visão computacional, processamento de linguagem natural e muitas outras áreas.

## 1.1 Objetivos de Aprendizagem

Ao final desta aula, o estudante será capaz de:

- Compreender a inspiração biológica das redes neurais
- Implementar um neurônio artificial (perceptron)
- Entender a relação entre neurônios e regressão logística
- Construir redes neurais feedforward simples
- Realizar o forward pass usando operações matriciais
- Identificar a necessidade de funções de ativação não-lineares

## 1.2 Conexão com a Aula Anterior

Na semana passada, estudamos:

- Regressão linear:  $y = \mathbf{w}^T \mathbf{x} + b$
- Descida de gradiente:  $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \nabla J(\mathbf{w}^{(t)})$
- Função de custo MSE:  $J(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Hoje veremos como esses conceitos se estendem para redes neurais, onde:

- Cada neurônio realiza uma operação similar à regressão
- Múltiplos neurônios são organizados em camadas
- A descida de gradiente continua sendo o método de otimização

# 2 Inspiração Biológica

## 2.1 O Neurônio Biológico

O neurônio biológico é a unidade fundamental do sistema nervoso. Suas principais componentes são:

- **Dendritos:** Recebem sinais de outros neurônios
- **Corpo celular (soma):** Processa e integra os sinais recebidos
- **Axônio:** Transmite o sinal de saída
- **Sinapses:** Conexões com outros neurônios

O neurônio biológico funciona de forma simplificada assim:

1. Recebe múltiplos sinais através dos dendritos
2. Integra esses sinais no corpo celular
3. Se a soma dos sinais excede um limiar, dispara um potencial de ação
4. Transmite o sinal através do axônio para outros neurônios

## 2.2 Do Biológico ao Artificial

O neurônio artificial é uma abstração matemática inspirada no neurônio biológico:

Neurônio Biológico	Neurônio Artificial
Dendritos	Entradas $(x_1, x_2, \dots, x_n)$
Força sináptica	Pesos $(w_1, w_2, \dots, w_n)$
Corpo celular	Função de agregação $(\sum)$
Limiar de ativação	Bias $(b)$
Potencial de ação	Função de ativação $(f)$
Axônio	Saída $(y)$

## 3 O Neurônio Artificial

### 3.1 Modelo Matemático

**Definição 3.1 (Neurônio Artificial)** *Um neurônio artificial é uma unidade computacional que:*

1. *Recebe um vetor de entrada  $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$*
2. *Calcula uma combinação linear ponderada:  $z = \mathbf{w}^T \mathbf{x} + b$*
3. *Aplica uma função de ativação:  $a = f(z)$*

Matematicamente:

$$a = f\left(\sum_{i=1}^n w_i x_i + b\right) = f(\mathbf{w}^T \mathbf{x} + b) \quad (1)$$

onde:

- $\mathbf{x} \in \mathbb{R}^n$  é o vetor de entrada
- $\mathbf{w} \in \mathbb{R}^n$  é o vetor de pesos

- $b \in \mathbb{R}$  é o bias (viés)
- $z = \mathbf{w}^T \mathbf{x} + b$  é chamado de "net input" ou entrada líquida
- $f : \mathbb{R} \rightarrow \mathbb{R}$  é a função de ativação
- $a$  é a saída (ativação) do neurônio

### 3.2 Relação com Regressão Logística

**Teorema 3.1 (Equivalência com Regressão Logística)** *Um neurônio artificial com função de ativação sigmoid é matematicamente equivalente à regressão logística.*

**Demonstração:** Na regressão logística, temos:

$$P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (2)$$

Um neurônio com ativação sigmoid calcula:

$$a = \sigma(z) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (3)$$

Portanto, são idênticos! A diferença está na interpretação:

- Regressão logística: modelo probabilístico para classificação binária
- Neurônio: unidade computacional que pode ser combinada em rede

## 4 Funções de Ativação

### 4.1 Por que Funções de Ativação?

Funções de ativação introduzem não-linearidade na rede neural. Sem elas, múltiplas camadas lineares colapsariam em uma única transformação linear.

**Teorema 4.1 (Composição de Funções Lineares)** *A composição de qualquer número de transformações lineares é ainda uma transformação linear.*

**Prova:** Sejam duas transformações lineares:  $f_1(\mathbf{x}) = W_1 \mathbf{x} + \mathbf{b}_1$  e  $f_2(\mathbf{x}) = W_2 \mathbf{x} + \mathbf{b}_2$ . A composição é:

$$f_2(f_1(\mathbf{x})) = W_2(W_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2 \quad (4)$$

$$= W_2 W_1 \mathbf{x} + W_2 \mathbf{b}_1 + \mathbf{b}_2 \quad (5)$$

$$= W_{comp} \mathbf{x} + \mathbf{b}_{comp} \quad (6)$$

onde  $W_{comp} = W_2 W_1$  e  $\mathbf{b}_{comp} = W_2 \mathbf{b}_1 + \mathbf{b}_2$ .

## 4.2 Função Sigmoid

A função sigmoid é uma das funções de ativação mais clássicas:

### Definição 4.1 (Função Sigmoid)

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (7)$$

#### Propriedades:

- Domínio:  $(-\infty, +\infty)$
- Imagem:  $(0, 1)$
- Interpretação probabilística
- Diferenciável em todo domínio
- Saturação para valores extremos

**Teorema 4.2 (Derivada da Sigmoid)** *A derivada da função sigmoid tem uma forma elegante:*

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (8)$$

#### Demonstração:

$$\sigma'(z) = \frac{d}{dz} \left( \frac{1}{1 + e^{-z}} \right) \quad (9)$$

$$= \frac{d}{dz} (1 + e^{-z})^{-1} \quad (10)$$

$$= -(1 + e^{-z})^{-2} \cdot (-e^{-z}) \quad (11)$$

$$= \frac{e^{-z}}{(1 + e^{-z})^2} \quad (12)$$

$$= \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}} \quad (13)$$

$$= \sigma(z) \cdot (1 - \sigma(z)) \quad (14)$$

Esta propriedade será extremamente útil quando calcularmos gradientes na retropropagação.

## 4.3 Outras Funções de Ativação Comuns

### 4.3.1 Tangente Hiperbólica (tanh)

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} = \frac{2}{1 + e^{-2z}} - 1 \quad (15)$$

#### Propriedades:

- Imagem:  $(-1, 1)$
- Centrada em zero
- Derivada:  $\tanh'(z) = 1 - \tanh^2(z)$

### 4.3.2 ReLU (Rectified Linear Unit)

$$\text{ReLU}(z) = \max(0, z) = \begin{cases} z & \text{se } z > 0 \\ 0 & \text{caso contrário} \end{cases} \quad (16)$$

Propriedades:

- Computacionalmente eficiente
- Não satura para valores positivos
- Problema do "dying ReLU"
- Derivada:  $\text{ReLU}'(z) = \begin{cases} 1 & \text{se } z > 0 \\ 0 & \text{caso contrário} \end{cases}$

## 5 Redes Neurais Feedforward

### 5.1 Arquitetura em Camadas

Uma rede neural feedforward organiza neurônios em camadas sequenciais:

**Definição 5.1 (Rede Neural Feedforward)** *Uma rede neural feedforward é composta por:*

1. **Camada de entrada:** *Recebe os dados (não realiza computação)*
2. **Camadas ocultas:** *Uma ou mais camadas de neurônios que processam informação*
3. **Camada de saída:** *Produz o resultado final*

A informação flui em uma única direção: entrada  $\rightarrow$  ocultas  $\rightarrow$  saída.

### 5.2 Notação

Para uma rede com  $L$  camadas:

- $l$  denota o índice da camada,  $l \in \{1, 2, \dots, L\}$
- $n^{(l)}$  é o número de neurônios na camada  $l$
- $W^{(l)} \in \mathbb{R}^{n^{(l-1)} \times n^{(l)}}$  é a matriz de pesos da camada  $l - 1$  para  $l$
- $\mathbf{b}^{(l)} \in \mathbb{R}^{n^{(l)}}$  é o vetor de bias da camada  $l$
- $\mathbf{z}^{(l)}$  é o vetor de net inputs da camada  $l$
- $\mathbf{a}^{(l)}$  é o vetor de ativações da camada  $l$

### 5.3 Forward Pass

O forward pass (propagação direta) calcula a saída da rede dado uma entrada:

**Exemplo 5.1 (Forward Pass)** *Para uma entrada  $\mathbf{x}$ , o forward pass calcula iterativamente:*

$$\mathbf{a}^{(0)} = \mathbf{x} \quad (17)$$

$$\mathbf{z}^{(l)} = W^{(l)T} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)} \quad \text{para } l = 1, \dots, L \quad (18)$$

$$\mathbf{a}^{(l)} = f^{(l)}(\mathbf{z}^{(l)}) \quad \text{para } l = 1, \dots, L \quad (19)$$

$$\hat{\mathbf{y}} = \mathbf{a}^{(L)} \quad (20)$$

### 5.4 Representação Matricial

Para processar múltiplas amostras simultaneamente, usamos notação matricial:

Seja  $X \in \mathbb{R}^{m \times n^{(0)}}$  uma matriz com  $m$  amostras (linhas).

$$A^{(0)} = X \quad (21)$$

$$Z^{(l)} = A^{(l-1)} W^{(l)} + \mathbf{1}_m \mathbf{b}^{(l)T} \quad (22)$$

$$A^{(l)} = f^{(l)}(Z^{(l)}) \quad (23)$$

$$\hat{Y} = A^{(L)} \quad (24)$$

onde  $\mathbf{1}_m$  é um vetor coluna de uns de tamanho  $m$ .

## 6 Exemplo Prático

### 6.1 Rede com 2 Camadas Ocultas

Considere uma rede neural com:

- Entrada: 3 features ( $n^{(0)} = 3$ )
- Primeira camada oculta: 4 neurônios ( $n^{(1)} = 4$ )
- Segunda camada oculta: 4 neurônios ( $n^{(2)} = 4$ )
- Saída: 3 classes ( $n^{(3)} = 3$ )

**Exemplo 6.1 (Cálculo do Forward Pass)** *Dado  $\mathbf{x} = [0.9, 0.2, 0.3]^T$  e pesos inicializados aleatoriamente, vamos calcular a saída.*

**Primeira camada oculta:**

$$\mathbf{z}^{(1)} = W^{(1)T} \mathbf{x} + \mathbf{b}^{(1)} \quad (25)$$

$$\mathbf{a}^{(1)} = \sigma(\mathbf{z}^{(1)}) \quad (26)$$

Se  $W^{(1)} \in \mathbb{R}^{3 \times 4}$  e  $\mathbf{b}^{(1)} \in \mathbb{R}^4$ , então  $\mathbf{a}^{(1)} \in \mathbb{R}^4$ .



*Segunda camada oculta:*

$$\mathbf{z}^{(2)} = W^{(2)T} \mathbf{a}^{(1)} + \mathbf{b}^{(2)} \quad (27)$$

$$\mathbf{a}^{(2)} = \sigma(\mathbf{z}^{(2)}) \quad (28)$$

*Camada de saída:*

$$\mathbf{z}^{(3)} = W^{(3)T} \mathbf{a}^{(2)} + \mathbf{b}^{(3)} \quad (29)$$

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{z}^{(3)}) \quad (30)$$

## 6.2 Função Softmax

Para problemas de classificação multiclasse, usamos softmax na camada de saída:

**Definição 6.1 (Função Softmax)**

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (31)$$

onde  $K$  é o número de classes.

Propriedades:

- Saída forma uma distribuição de probabilidade
- $\sum_{i=1}^K \text{softmax}(\mathbf{z})_i = 1$
- $0 < \text{softmax}(\mathbf{z})_i < 1$  para todo  $i$

## 7 Por que Redes Profundas?

### 7.1 Limitações de um Único Neurônio

Um único neurônio (como na regressão logística) só pode aprender fronteiras de decisão lineares. Isso limita severamente os problemas que podem ser resolvidos.

**Exemplo 7.1 (Problema XOR)** *O problema XOR não é linearmente separável:*

$x_1$	$x_2$	$XOR$
0	0	0
0	1	1
1	0	1
1	1	0

*Não existe uma linha reta que separe as classes 0 e 1.*

### 7.2 Poder das Redes Multicamadas

**Teorema 7.1 (Teorema da Aproximação Universal)** *Uma rede neural feedforward com uma única camada oculta contendo um número finito de neurônios pode aproximar qualquer função contínua em subconjuntos compactos de  $\mathbb{R}^n$ , sob suposições brandas sobre a função de ativação.*

Este teorema, provado por Cybenko (1989) e Hornik (1991), garante que redes neurais são aproximadores universais de funções.

### 7.3 Profundidade vs. Largura

Embora uma única camada oculta seja teoricamente suficiente, redes profundas (múltiplas camadas) são mais eficientes:

- **Redes rasas e largas:** Precisam de exponencialmente mais neurônios
- **Redes profundas:** Aprendem representações hierárquicas
- **Composicionalidade:** Camadas sucessivas aprendem features cada vez mais abstratas

## 8 Conclusão

Nesta segunda aula, estabelecemos os fundamentos das redes neurais artificiais, fazendo a transição natural dos métodos tradicionais de machine learning para arquiteturas mais sofisticadas e poderosas.

### 8.1 Principais Conceitos Abordados

Exploramos os conceitos fundamentais que formam a base das redes neurais modernas:

- A inspiração biológica dos neurônios artificiais e como ela se traduz em modelos matemáticos elegantes
- A equivalência entre um neurônio artificial e a regressão logística, demonstrando a continuidade conceitual
- A importância crítica das funções de ativação não-lineares para conferir poder expressivo às redes
- A arquitetura feedforward e sua representação matricial eficiente
- O forward pass como processo computacional fundamental