Redes Neurais Recorrentes

Eduardo Adame

Redes Neurais

12 de novembro de 2025

O Desafio: Sequências de Comprimento Variável

- Com imagens, forçamos uma dimensão de entrada específica
- Não é óbvio como fazer isso com texto ou outras sequências
- **Exemplo:** Classificar tweets como positivos, negativos ou neutros
- Tweets podem ter um número variável de palavras
- **Outros exemplos:**
  - Análise de séries temporais (preços de ações)
  - Reconhecimento de fala
  - Tradução automática
  - Análise de sequências de DNA

O Problema da Ordem das Palavras

- Queremos fazer melhor que implementações de "bag of words" (saco de palavras)
- Idealmente, cada palavra é processada ou compreendida no contexto apropriado
- Precisamos ter alguma noção de **"contexto"**
- As palavras devem ser tratadas de forma diferente dependendo do contexto
- Além disso, cada palavra deve atualizar o contexto

Exemplo

"O banco estava cheio" vs "O banco do parque estava vazio"
A palavra "banco" tem significados diferentes dependendo do contexto!

Ideia: Usar o Conceito de "Recorrência"

- Processar palavras uma por uma
- A rede produz duas saídas:
  1. **Predição:** Qual seria a predição se a sequência terminasse naquela palavra
  2. **Estado:** Resumo de tudo que aconteceu no passado
- Dessa forma, podemos lidar com comprimentos variáveis de texto
- A resposta a uma palavra depende das palavras que a precederam

Visualização da Recorrência

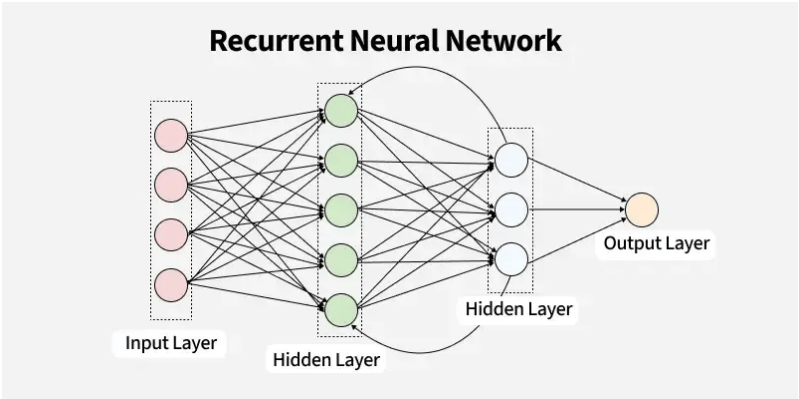

O estado é **recorrente** - ele se alimenta de volta para a próxima etapa temporal!

“Desenrolando” a RNN

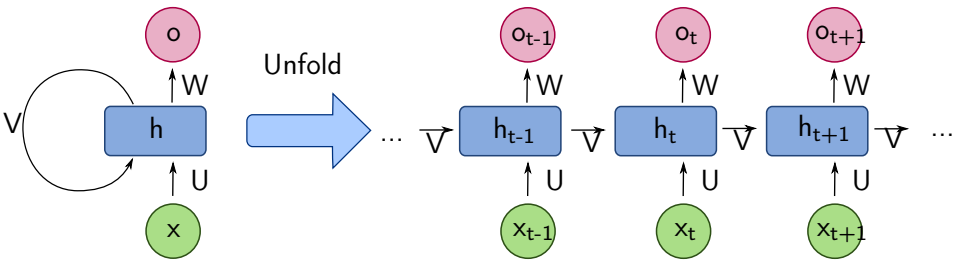

Visualização “desenrolada” no tempo ajuda a entender o fluxo de informação

Componentes da RNN Desenrolada

Elementos:

- w_i: palavra na posição i
- s_i: estado na posição i
- o_i: saída na posição i
- U: pesos de entrada (kernel)
- W: pesos recorrentes
- V: pesos de saída

Importante:

Compartilhamento

As matrizes U, W, V são as **mesmas** em todas as posições temporais!

Isso permite generalização através do tempo e reduz drasticamente o número de parâmetros.

Exemplo Prático

Considere a frase: **"Isso é ótimo!"**

Posição	**Palavra**	**Estado**	**Predição**
1	"Isso"	s_1	?
2	"é"	s_2	?
3	"ótimo"	s_3	+
4	"!"	s_4	++

- A predição fica mais confiante à medida que mais palavras são processadas
- O estado s_i carrega informação de todas as palavras anteriores

Fórmulas das RNNs

Equações Fundamentais

$$s_i = f(Uw_i + Ws_{i-1}) \quad \text{(RNN principal)}$$
$$o_i = \text{softmax}(Vs_i) \quad \text{(camada densa subsequente)}$$

Em outras palavras:

- estado atual = função(estado anterior, entrada atual)
- saída atual = função(estado atual)
- Aprendemos as funções através do treinamento da rede!

f é tipicamente uma função de ativação não-linear (tanh ou ReLU)

Dimensões das Matrizes

- r = dimensão do vetor de entrada
- s = dimensão do estado oculto
- t = dimensão do vetor de saída (após camada densa)

Dimensões das Matrizes de Peso

- U é uma matriz $s \times r$
- W é uma matriz $s \times s$
- V é uma matriz $t \times s$

Nota importante: As matrizes U, V, W são as mesmas em todas as posições temporais.

Componentes no Keras/TensorFlow

- **Matriz U (kernel):** Controlada por `kernel_initializer`
- **Matriz W (recorrente):** Controlada por `recurrent_initializer`
- **Matriz V (saída):** Implementada como uma camada `Dense` subsequente

Listing 1: Exemplo de Código

```
model.add(SimpleRNN(units=128,
                    kernel_initializer='glorot_uniform',
                    recurrent_initializer='orthogonal'))
model.add(Dense(num_classes, activation='softmax'))
```

Detalhes Práticos de Implementação

- Frequentemente, treinamos apenas na saída "final" e ignoramos as saídas intermediárias
- Uma variação chamada **Backpropagation Through Time (BPTT)** é usada para treinar RNNs
- Sensível ao comprimento da sequência (devido ao problema de "gradiente desaparecendo/explodindo")
- Na prática, ainda definimos um comprimento máximo para nossas sequências:
  - Se a entrada é mais curta, fazemos **padding** (preenchimento)
  - Se a entrada é mais longa, truncamos

Exemplo de Código: Preparação dos Dados

Listing 2: Pré-processamento de Sequências

```
from tensorflow.keras.preprocessing import sequence

# Definir comprimento máximo
max_length = 100

# Padding das sequências
X_train = sequence.pad_sequences(X_train,
                                 maxlen=max_length,
                                 padding='post',
                                 truncating='post')
```

`padding='post'`: Adiciona zeros no final
`truncating='post'`: Corta no final se exceder max_length

Exemplo de Código: Construindo o Modelo

Listing 3: Modelo RNN Simples para Classificação de Sentimento

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense

model = Sequential([
    Embedding(vocab_size, embedding_dim,
              input_length=max_length),
    SimpleRNN(64, return_sequences=False),
    Dense(1, activation='sigmoid')
])

model.compile(optimizer='adam',
              loss='binary_crossentropy',
              metrics=['accuracy'])
```

Embedding Layer

- Antes de processar palavras, precisamos convertê-las em vetores numéricos
- **Embedding** aprende uma representação densa de palavras
- Cada palavra é mapeada para um vetor de tamanho fixo
- Palavras semanticamente similares terão embeddings próximos

Exemplo

Palavra	Embedding (simplificado)
"bom"	[0.8, 0.3, -0.1, ...]
"ótimo"	[0.85, 0.35, -0.05, ...]
"ruim"	[-0.7, -0.4, 0.2, ...]

Aplicações de RNNs (2025)

Processamento de Linguagem Natural:

- Análise de sentimento
- Classificação de textos
- Geração de texto (chatbots básicos)
- Modelagem de linguagem

Séries Temporais:

- Previsão de preços de ações
- Previsão de demanda de energia
- Análise de dados climáticos
- Monitoramento de sensores IoT

Mais Aplicações de RNNs

Reconhecimento de Fala:

- Transcrição de áudio para texto
- Comandos de voz

Bioinformática:

- Análise de sequências de DNA
- Predição de estrutura de proteínas
- Classificação de sequências genômicas

Outras Aplicações:

- Reconhecimento de escrita manuscrita
- Análise de vídeo (frame por frame)
- Detecção de anomalias em séries temporais

Exemplo Interativo Online

TensorFlow Playground - RNN Visualizer

URL: `https://distill.pub/2019/memorization-in-rnns/`

Este site interativo permite:

- Visualizar como RNNs processam sequências
- Ver como o estado oculto evolui ao longo do tempo
- Experimentar com diferentes arquiteturas
- Entender o problema de memória de longo prazo

Problema do Gradiente Desaparecendo/Explodindo

Gradiente Desaparecendo:

- Gradientes ficam muito pequenos
- Informação do passado distante é "esquecida"
- Dificuldade em aprender dependências de longo prazo

Gradiente Explodindo:

- Gradientes ficam muito grandes
- Instabilidade no treinamento
- Pode ser mitigado com gradient clipping

Exemplo

Tentando lembrar o sujeito de uma frase: *"O homem que ... muitas palavras ... estava cansado"*
RNNs simples têm dificuldade em manter "homem" na memória.

Limitações das RNNs Simples

- **Memória de curto prazo:** Dificuldade em manter informação do passado distante sem reforço
- **Processamento sequencial:** Não pode ser facilmente paralelizado
- **Sensibilidade ao comprimento:** Performance degrada com sequências muito longas
- **Treinamento lento:** Backpropagation through time é computacionalmente custoso

Solução

Na próxima aula, veremos **LSTMs (Long Short-Term Memory)**, que foram projetadas especificamente para resolver esses problemas!

Comparação: RNN vs Outras Arquiteturas (2025)

Arquitetura	Paralelização	Memória	Uso em 2025
RNN Simples	×	Curto prazo	Limitado
LSTM/GRU	×	Longo prazo	Moderado
Transformers	✓	Atenção total	Dominante
CNN 1D	✓	Local	Específico

Nota: Embora Transformers dominem em 2025, RNNs ainda são:

- Fundamentais para entender arquiteturas modernas
- Úteis em cenários com recursos limitados
- Base para variantes mais eficientes

Long Short-Term Memory (LSTM)

O que veremos:

- Arquitetura LSTM: gates de entrada, saída e esquecimento
- Como LSTMs resolvem o problema do gradiente desaparecendo
- Variante GRU (Gated Recurrent Unit)
- Aplicações práticas: tradução automática, chatbots, geração de texto
- Implementação em TensorFlow/Keras
- Comparação RNN vs LSTM vs GRU

Referências e Recursos

Leitura Recomendada:

- Goodfellow et al. - Deep Learning, Capítulo 10 (RNNs)
- https://colah.github.io/posts/2015-08-Understanding-LSTMs/

Tutoriais Interativos:

- TensorFlow RNN Tutorial: https://www.tensorflow.org/text/tutorials/text_classification_rnn
- Distill.pub - Visualizações de RNNs

Vídeos Complementares:

- Stanford CS231n - Lecture 10 (RNNs)
- 3Blue1Brown - Neural Networks series

Obrigado!

Dúvidas?